Preguntas de Parciales Para Desarrollar

1. **¿Cuál es el principio en el cual se basa el modelo Naives Bayes?**

   El modelo Naive Bayes se basa en el Teorema de Bayes, que establece una forma de calcular la probabilidad de que ocurra un evento dado que ya se ha observado otro evento. En términos de clasificación, este teorema permite calcular la probabilidad de una clase específica, dados ciertos atributos o características de los datos.

   La fórmula general del Teorema de Bayes es:

$$p(e_i \mid s) = \frac{p(e_i) \cdot p(s \mid e_i)}{\sum_{j=1}^{n} p(e_j) \cdot p(s \mid e_j)}$$

$$\text{Para} \quad i = 1,\ldots,n$$

   donde

   - ***p(ei)** es la probabilidad a priori, probabilidad de ocurrencia de esa clase antes de que se observen los datos.*
   - ***p(s\|ei)** es la probabilidad condicional, es decir la cantidad de elementos de la clase ei sobre el espacio muestral s.*
   - ***p(ei) * p(s/ei)** es la probabilidad total, es decir la probabilidad de que aparezcan elementos de cualquier clase en el espacio muestral.*

2. **¿Cómo se podría solucionar una red MLP cuyo error de validación crece antes de llegar al mínimo aceptable? ¿Podría ser agregado el término momento para filtrar este tipo de oscilaciones?**

   Cuando el error de validación de una red MLP crece antes de llegar al mínimo aceptable lo primero que se debe hacer es una parada temprana para cambiar la estructura de la red, se pueden agregar capas y/o nodos, también se debe cambiar la función de activación y reiniciar los pesos iniciales.
   El término momento lo único que aporta es que acelera la convergencia y por ende solo obtendremos antes el error de validación. Evitar oscilaciones y acelerar la convergencia no soluciona el problema

3. **¿Cómo se implementaría una red MLP para que reconozca una función f(x,y)=sen(xy)-0,5?**

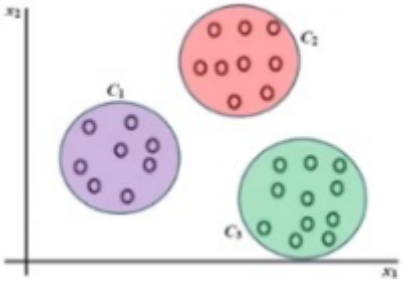
   Para implementar una MLP que reconozca la función f(x,y)=sin(xy)−0.5, primero se debe generar un dataset con valores de (x,y) y su correspondiente f(x,y). La red tendrá dos neuronas en la capa de entrada (una para x y otra para y), varias capas ocultas con n

neuronas cada una, y una neurona en la capa de salida. En la capa de la salida es recomendable usar una función de activación tangencial para ajustarse mejor al comportamiento senoidal. El modelo se entrena minimizando el error y evaluando su desempeño en datos de prueba para ajustar los hiperparámetros según sea necesario.

4. **En cluster jerárquico, ¿qué ocurre si se calcula de manera distinta los centroides?**

   No ocurre nada, debido a diferencia de los algoritmos k-means que usa únicamente centroides para medir la distancia, en clustering jerárquico se utilizan otros métodos para determinar la distancia entre dos clusters:
   - *Single – Link Method*
   - *Complete – Link Method*
   - *Average – Link Method*

5. **Dado el siguiente conjunto de datos en R^2 explique las características que debe tener en cuenta para implementarla en una red MLP. Tenga en cuenta la descripción de las etapas de entrenamiento y funcionamiento.**



   Arquitectura *la arquitectura necesaria para implementar la red MLP solicitada:*
   - *dos neuronas de entrada (x1, x2)*
   - *dos neuronas de salidas codificadas para identificar cada clase 000 =c1, 001 =c2, 011 = c3.*
   - *Funciones de activación sigmoidal.*

   Además, se debe:
   - *Definir el error medio que detiene el entrenamiento*
   - *Definir coeficiente de aprendizaje alfa y término de momento beta si existe.*
   - *Dividir los datos en conjuntos entrenamiento y test.*
   - *Medir error de entrenamiento para verificar si se alcanzó el mínimo y también medir el error de validación para evitar overfitting.*

6. **Cuando se utiliza la Average Link en clustering jerárquico, la distancia entre dos clusters se obtiene como promedio de todas las distancias entre los elementos de cada clúster. ¿Esto es equivalente a calcular la distancia entre los centroides de los dos clusters?**

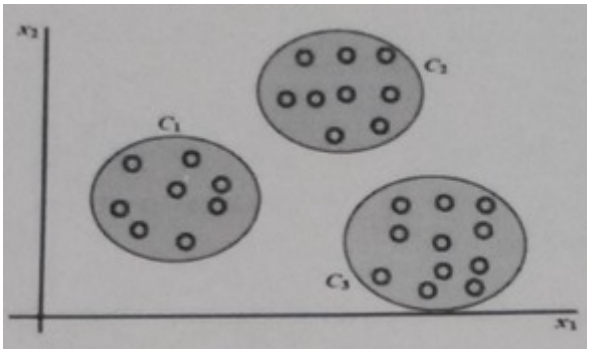
   No, no es lo mismo. En Average Link la distancia se calcula considerando todos los pares de datos, uno de cada clúster, sumando esas distancias y luego promediándolas. Por otro lado, el centroide es el punto medio de un clúster, calculado como el promedio de sus datos, pero no tiene en cuenta las distancias hacia los datos del otro clúster. En el caso de la distancia

entre centroides, solo se mide entre los puntos promedio de cada clúster, sin involucrar directamente los datos individuales de ambos clústeres como en Average Link.

7. **En la etapa de cooperación del algoritmo de entrenamiento de los SOM se establece que los pesos asociados a las neuronas de salida se actualizan en función de la distancia a la que estas se encuentran de la neurona ganadora. ¿Cómo se mide esa distancia y cómo afecta a la actualización de los pesos de la red?**

   Para medir la distancia es necesaria una función que pueda computar la similitud entre los datos, aquellos datos que sean similares entre sí serán más cercanos entre ellos. En el caso de los datos numéricos, un método sencillo es calcular la distancia euclídea, aunque es probable que no sea recomendable en ciertos problemas.
   Las neuronas que se encuentren más cerca de la ganadora (i.e. que tengan mayor similitud) recibirán mayor influencia a la hora de actualizar sus pesos mediante la ***función de vecindad.*** *Esto quiere decir que sus pesos variarán más que aquellas neuronas más alejadas.*

8. **Dado el siguiente conjunto de datos en R^2 explique cómo implementar:**
   a. Una red del tipo MLP Respuesta en Pregunta 5
   b. Un clasificador basado en NB



   El clasificador bayesiano utiliza el teorema de Bayes para calcular la probabilidad de que un dato x=(x1,x2) pertenezca a una clase específica Ck. Requiere conocer o estimar la distribución de los datos P(x|Ck), que generalmente se asume como gaussiana, y las probabilidades a priori P(Ck), que dependen de la proporción de ejemplos en cada clase. Para predecir, calcula la probabilidad posterior P(Ck |x) para cada clase y selecciona la de mayor valor. Este enfoque es eficiente, pero depende de las suposiciones sobre la distribución de los datos y la independencia entre características.
   Dado que los atributos son continuos, podemos calcular el clasificador bayesiano utilizando histogramas, y dividiendo en bins el espacio muestral.
   Las instancias se clasificarían con la probabilidad a priori de la clase Ck por la productoria de las probabilidades de que pertenezca a la clase Ck dentro del bin para cada atributo.

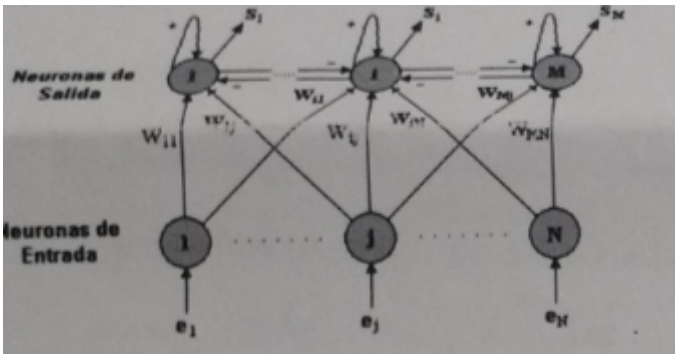
9. **¿Cuáles son los factores principales para considerar en el aprendizaje basado en ajuste de parámetros?**

Un programa basado en el ajuste de parámetros debe considerar dos cosas para que sea considerado bueno el sistema pueda estabilizarse:

- *En qué momento debe aumentar o disminuir el valor de un parámetro. Es decir, cuando hacer el ajuste. Esto está bien determinado en ciertos modelos, pero si se hiciera constantemente sin control, es probable que el ajuste nunca pueda converger a parámetros estables.*
- *Magnitud del ajuste. Cuánto aumentar o cuánto disminuir.*

Si esas dos cosas se pueden controlar bien, el programa por ajuste de parámetros va a funcionar bien. Mientras que si alguna de estas dos características no está bien implementada, no va a funcionar.

10. **¿A qué modelo corresponde la siguiente arquitectura de red neuronal? Explique el funcionamiento del algoritmo de aprendizaje de este modelo indicando las características principales.**



La arquitectura de red neuronal presentada corresponde al modelo SOM. El algoritmo de aprendizaje del modelo SOM funciona de la siguiente manera:

1. *Inicializar los pesos de las conexiones con valores pequeños y determinar el espacio de la función de vecindad.*
2. *Presentar vector de entrada Ek*
3. *Calcular la salida - Fase de competencia - elegir neurona ganadora (distancia)*
4. *Actualizar pesos*
5. *Volver al paso 2*

El proceso no termina con la presentación de todos los patrones sino cuando se estabilice la red, esto es, la variación de pesos sea menor a un umbral o nula.

11. **¿Cuál es el factor determinante en el aprendizaje basado en explicaciones? Justifique la respuesta.**

El aprendizaje basado en explicaciones tiene el mismo concepto del aprendizaje basado en consejo, pero se diferencia en que requiere una gran cantidad de conocimiento sobre el dominio aplicación para aplicarlo. Cuanto más alto sea el conocimiento del dominio de aplicación, mejor, ya que un solo ejemplo hace que se entienda y pueda generalizar el resto.

Notas:

- *En un sistema basado en explicaciones se intenta aprender a partir de un ejemplo X, explicando por qué X es un ejemplo del concepto distinto. Y luego de la explicación se generaliza y la validez del conocimiento mejora el resultado del sistema.*
- ***Aprendizaje por consejo:*** *Para que se de aprendizaje por consejo hay que traducir los consejos que da el programador a alto nivel a acciones que la computadora pueda entender.*

12. ¿Qué es y para qué se utiliza el término de momento en redes MLP?

El término de momento se utiliza para acelerar la convergencia de la red durante el entrenamiento, reduciendo el número de iteraciones necesarias para alcanzar el mínimo del error. Esto se logra añadiendo un término adicional, denominado "momento" (β), a la ecuación de actualización de pesos. β es una constante que determina el efecto en t+1 del cambio de los pesos en t, teniendo en cuenta el peso actual y el anterior para definir el incremento.

13. Proponga una solución para una red MLP que finaliza el entrenamiento porque el error de validación crece antes de alcanzar el mínimo aceptable.

Para solucionar el problema de una red MLP cuyo error de validación crece antes de alcanzar un mínimo aceptable, se pueden tomar las siguientes acciones:

- *Verificar y mejorar la calidad del dataset de entrenamiento, asegurándose de que esté correctamente mezclado y representado, para evitar que el modelo se sobreentrene en patrones específicos. Después de este ajuste, reentrenar la red neuronal.*
- *Ajustar los hiperparámetros como el coeficiente de aprendizaje y el término de momento (β) si se está utilizando. Reducir el coeficiente de aprendizaje puede estabilizar el entrenamiento, mientras que un β adecuado puede ayudar a suavizar las actualizaciones y prevenir oscilaciones.*
- *Reiniciar los pesos establecidos*
- *Cambiar la función de transferencia y/o la arquitectura de la red*

Estas medidas ayudan a mitigar el sobreajuste y mejoran la capacidad de generalización del modelo, favoreciendo un entrenamiento más estable y eficaz.

14. Explique el funcionamiento de SOM Respuesta en Pregunta 10
15. **Compare los modelos de SOM, Hopfield y de Perceptrón, teniendo en cuenta los siguientes aspectos:**
    a. **cantidad de entradas**
    b. **cantidad de salidas**
    c. **aprendizaje online/offline**
    d. **aprendizaje supervisado/no supervisado**
    e. **condición de finalización del aprendizaje,**
    f. **función de transferencia de la/s salida/s.**
    g. **limitaciones**
    h. **ejemplo de implementación.**

	SOM	Hopfield	Perceptrón
Cantidad de Entradas	*N entradas*	*N entradas*	*N entradas*
Cantidad de Salidas	*M salidas*	*N salidas*	*1 salida*
Apr. online/offline	*Offline*	*Offline*	*Offline*
Apr. Super/no Super	*No Supervisado*	*No Supervisado*	*Supervisado*
Condición de finalización del aprendizaje	*Cuando se estabilizan los pesos*	*S(t)=S(t+1), la red se estabiliza adecuadamente. Si S(t)=S(t+n) con n>1 no se estabiliza adecuadamente*	*Todos los errores del patrón deben ser iguales = 0*
Función de Transferencias de la/s salida/s	*Continua, lineal o sigmoidal*	*Escalón, sigmoidal o hiperbólica*	*Escalón*
Limitaciones	*Duración del proceso de aprendizaje, por la fase de competencia y fase de cooperación. No es adecuado para estructura de datos complejas*	*Limitaciones para almacenar información. Ortogonalidad de las entradas.*	*Los datos se separan por una recta, que sea linealmente separables. La función escalón produce saltos abruptos en la salida.*
Ejemplo de Implementación	*Reconocimiento de patrones (voz, texto, imágenes, señales)*	*Reconocimiento de patrones (voz, texto, imágenes, señales)*	*Clasificación de correo electrónico como correo no deseado o legítimo (spam). Clasificación de imágenes,textos.*

16. Compare los modelos knn, k-means y NB, teniendo en cuenta los siguientes aspectos:

- **a. dimensionalidad (cantidad de atributos que pueden manejar).**
- **b. cantidad de clases y/o clusters que pueden generar.**
- **c. aprendizaje online/offline.**
- **d. aprendizaje supervisado/no supervisado.**
- **e. condición de finalización del aprendizaje.**
- **f. Limitaciones**

	KNN	K-means	Naive Bayes
Tipo	*Clasificador*	*Agrupador*	*Clasificador*
Dimensionalidad	*Mínimo 1, no tiene máximo*	*Mínimo 1, no tiene máximo*	*Mínimo 1, no tiene máximo*
Cant de Clases/ Clusters que pueden generar	*El algoritmo no tiene máximo, este está dado por la cantidad de instancias de entrenamiento.*	*El algoritmo no tiene un máximo, este está dado por la cantidad de instancias de entrenamiento*	*El algoritmo no tiene un máximo.*
Apr. online/offline	*Aprendizaje offline*	*Aprendizaje offline*	*Aprendizaje offline*
Apr. Super/no Super	*Supervisado*	*No Supervisado*	*Supervisado*

Condición de finalización del aprendizaje	*Construir una lista con todos los ejemplos de entrenamiento.*	*El aprendizaje termina cuando se repiten los centroides*	*Una vez que se tiene las probabilidades a priori y verosimilitudes*
Limitaciones	*Para estructuras de dato tipo vecindario. Cuando posee muchos vecinos que pertenecen a la misma clase.*	*Si hay una mala agrupación de los clusters puede llevar a malas clasificaciones. Sensibles a las selecciones de centroides iniciales.*	*Los datos pueden no ajustarse a la distribución elegida. Si hay paridad en la cantidad de elementos, se inclinará la clasificación por la clase de mayores elementos.*

17. Explique el proceso de aprendizaje del modelo ADALINA y las diferencias con el modelo PERCEPTRÓN simple.

- *Modelo ADALINA El modelo adaline es una red de una sola neurona en donde se utiliza la regla delta que nos permite calcular el error de la red a través del error cuadrático medio. Esto se da ya que la función de activación de esta red es la identidad y por lo tanto el rango de las salidas es de (-inf, inf) de esta manera se pierde el control del error, para esto, lo que hacemos es hacerlo tender a 0, para esto utilizamos el error cuadrático medio en donde el error está dado por los PESOS.*
- *Modelo Perceptrón Simple El aprendizaje en perceptrón simple ocurre cuando se actualizan los pesos de sus conexiones. Al presentar un patrón y al calcular la salida, se obtiene un resultado distinto al deseado, esto produce un error que da lugar a la actualización de los pesos. Este proceso se repite hasta que no exista error para todos los patrones de entrada, en otras palabras, que el error global sea igual a 0.*

Diferencias entre los modelos:

- *El error en perceptrón sólo puede valer -1, 0 o 1 porque su salida es binaria 0 o 1. En ADALINE, existe salida lineal que da como resultado un error que puede ser cualquier número real y se aplica la regla Delta (o error cuadrático medio) para minimizar el error observado a la salida de la red y el deseado. Esta no parece una gran diferencia, pero la forma de la curva al aplicar error cuadrático medio con salida lineal es mucho más suave que cuando se usa salida binaria (perceptrón).*
- *La regla delta requiere de funciones de transferencias que sean derivables y, por lo tanto, continuas, por eso no se puede usar la función escalón.*

18. Explique cómo solucionar el problema de sobreajuste en el algoritmo k-means.

Para abordar el problema de sobreajuste en el algoritmo k-means, se pueden aplicar las siguientes estrategias:

- *Cambiar la distancia por la distancia de Mahalanobis Esto puede ayudar a identificar clusters más significativos y evitar particiones excesivamente específicas.*
- *Cambiar el valor de la semilla inicial puede reducir el riesgo de caer en mínimos locales que generen clusters inapropiados y poco generalizables.*

- *Utilizar otra técnica puede ser agrupamiento jerárquico este método no requiere predefinir el número de clusters y puede proporcionar una vista más completa de las relaciones entre los datos, lo que evita resultados sesgados por una mala elección de k.*
- *Probar distintos valores de k*

19. Explique cómo se implementa el algoritmo NB con distribuciones continuas.

El algoritmo NB con distribuciones continuas funciona asumiendo que las verosimilitudes de cada atributo de cada dato del dataset sigue un tipo de distribución, de esta manera reemplaza la verosimilitud por la distribución de probabilidad asumida.
Para aplicar la expresión de la distribución de probabilidad se tiene que analizar los datos y, a partir de allí, calcular la verosimilitud por medio de una fpd dada por f(x), entonces se debe:

1. *Calcular la media para cada dimensión de cada clase. Aquí utilizamos los ejemplos del set de entrenamiento.*

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$$

2. *Luego calculamos de la misma manera el desvío estándar.*

$$\sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}}$$

3. *Cuando se tiene la media y el desvió estándar, se debe calcular la verosimilitud a través de la función.*

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

4. *Una vez que se tienen las probabilidades a priori y las verosimilitudes, se determina:*

$$v_{NB} = \underset{v_j \in V}{\operatorname{argmax}} \left[P(v_j) \prod_i P(a_j | v_j) \right]$$

5. *Para determinar la clase más probable dada una instancia de prueba:*

$$c = argmax\ Pr\ (C = c_i) \prod_{i=1}^{|A|} Pr\ (A_i = a_i | C = c_i)$$

$$Pr\ (C = c_i) = \frac{número\ de\ ejemplos\ de\ la\ clase\ cj}{número\ total\ de\ ejemplos\ en\ el\ data\ set}$$

6. *Si se puede realizar el conteo se utiliza la siguiente fórmula para el cálculo de las verosimilitudes:*

$$Pr\ Pr\ (A_i = a_i | C = c_i) = \frac{número\ de\ ejemplos\ con\ el\ atributo\ Ai\ = ai\ de\ la\ clase\ cj}{número\ total\ de\ ejemplos\ de\ clase\ cj}$$

20. En un problema de clasificación donde se utiliza k-nn ponderado, con pesos wi= 1/ (1+ [d(x0,xi)^2]), se tienen dos clases A con m instancias y B con n instancias. Evalúe qué sucede si se utiliza k =m+n, suponga que m>n, m=n y m<n.

Si se utiliza $k = m + n$ en un problema de clasificación con k-NN ponderado, el comportamiento del algoritmo depende de la relación entre m (número de instancias de la clase A) y n (número de instancias de la clase B):

- *Si m>n: La nueva instancia probablemente pertenecerá a la clase A, ya que hay más vecinos de esta clase en el conjunto de entrenamiento. Aunque se ponderen los pesos según wi = 1/[1+d(x0 ,xi)^2] , la predominancia de la clase A en la cantidad total de vecinos será el factor decisivo.*
- *Si m<n: De manera análoga, la nueva instancia probablemente pertenecerá a la clase B, ya que esta tiene más vecinos en el conjunto de entrenamiento. La clase con más instancias tenderá a dominar debido a su mayoría relativa, incluso con la ponderación aplicada.*
- *Si m=n: En este caso, la decisión dependerá únicamente de los pesos asignados a los vecinos más cercanos. La clase de los vecinos que estén más próximos a la nueva instancia (es decir, aquellos con mayores pesos) será la que determine la clasificación. Este escenario resalta la importancia de la ponderación basada en la distancia.*

21. Explicar el funcionamiento de Hopfield y sus condiciones de cierre.

El funcionamiento del modelo puede especificarse como sigue:

1. *En el instante inicial (t=0), se aplica la información de entrada (es decir los valores e1, e2, …, eN)*
2. *La red realizará iteraciones hasta alcanzar la convergencia (es decir que si(t+1) sea igual a st(t). Siendo:*

$$s_i(t+1) = f\left(\sum_{j=1}^{N} w_{ij} s_j(t) - \theta_i\right) \qquad 1 \le i \le N$$

- *Condición de cierre: Si la repetición se da entre s(t) y s(t+1) se establece que la red se estabiliza. Si la repetición se da entre s(t) y s(t+n) (con n>1) se establece que la red no se estabiliza. En es decir que el ciclo de estabilización es 1, con la salida siguiente, igual a la actual. Si el ciclo de estabilización es mayor a 1, nunca se va a estabilizar.*

Otra Respuesta:

- *Una vez estabilizados los pesos de la red con las informaciones que se quiere que la red memorice comienza la fase de funcionamiento. Se presenta un patrón a la entrada, la red evoluciona hasta estabilizarse (S(t) == S(t+1) y devuelve a la salida la información almacenada que coincide con la presentada a la entrada. Si la información presentada no coincide con ninguna de las almacenadas, devuelve la más parecida.*
- *La salida se calcula, eso da net y luego a net función escalón.*

$$S_{(t+1)} = E_d \cdot W$$
$$E_d = S_{(t+1)}$$

22. Explique el modelo k-cross validation y su relación con Knn.

El método k-cross fold validation es un método para determinar el K óptimo, el cual es el k con el que se produce menos error a la hora de clasificar.
Sea D el conjunto de entrenamiento con N instancias, este método consiste en calcular las distancias entre cada par de instancias en D y luego la clasificación de cada elemento del conjunto de entrenamiento contra el resto.
En cuanto a su relación con el algoritmo de k-vecinos más cercanos (KNN), el K-fold cross validation se utiliza comúnmente para ajustar los parámetros del modelo KNN. En el proceso de ajuste de parámetros, se varía el valor de k (el número de vecinos más cercanos considerados en la predicción) y se utiliza K-fold cross validation para evaluar el rendimiento del modelo para cada valor de k. Luego, se selecciona el valor de k que proporciona el mejor rendimiento en el conjunto de datos de validación.

23. Explicar qué hacer cuando el Error de validación < Error mínimo aceptable.

Cuando el error de validación es menor que el error mínimo aceptable, significa que la red ha logrado un buen rendimiento en la tarea de generalización y se ha ajustado correctamente a los datos de entrenamiento y validación. En este caso, se puede detener el proceso de entrenamiento ya que no se espera una mejora significativa en el rendimiento de la red.
Sin embargo, si el error de validación es mayor que el error mínimo aceptable, significa que la red no está generalizando adecuadamente y es necesario seguir ajustando los pesos de la red. En este caso, se puede continuar el proceso de entrenamiento y ajustar los parámetros de la red (como la tasa de aprendizaje, el número de capas y neuronas, etc.) para mejorar el rendimiento de la red en los datos de validación.

24. ¿Cuál es la diferencia entre el aprendizaje supervisado y aprendizaje por refuerzo?

El aprendizaje supervisado se da cuando existe un agente externo que le dice al programa, algoritmo o sistema que lo que está haciendo está bien o está mal. Es decir, necesita un agente externo que supervise el aprendizaje.
Mientras que el aprendizaje por refuerzo se trata de un aprendizaje por interacción con el entorno. La recompensa por la tarea se la da el ambiente al agente sin decirle si está bien o está mal. Entonces, el entorno devuelve una respuesta positiva o negativa que permite que se ajusten los parámetros internos.

25. Mencione todos los problemas de reconocimiento que puede tener una red neuronal Hopfield.

En el modelo de Hopfield si se almacenan demasiados patrones en una red, esta no solamente puede dar una salida no estable, sino que puede estabilizarse en patrones que son desconocidos.
Existen dos condiciones de recuperabilidad:

$$\text{Capacidad} = \begin{cases} 0.138N & \text{para una recuperación buena} \\ \dfrac{N}{4\ln(N)} & \text{para una recuperación perfecta} \end{cases}$$

26. ¿Cuál es la razón de iniciar los valores optimistas en el proceso de aprendizaje por refuerzo?

Iniciar con valores optimistas en el aprendizaje por refuerzo tiene como objetivo fomentar la exploración de acciones en las etapas iniciales del entrenamiento. Al asignar inicialmente a las acciones valores altos (optimistas), el agente tiende a probar todas las opciones disponibles, incluso aquellas que podrían parecer subóptimas al principio.

27. ¿Cuáles son los problemas de NB con distribución de probabilidades (gaussiana, etc)?

No puede solucionar el problema de los espirales en los datos; por ejemplo, siempre que los datos están muy mezclados entre sí, es difícil segregarlos. Cómo trabaja haciendo separaciones lineales entre los mismos, en dichos casos mencionados, las clasificaciones que puede llegar a generar suelen tener errores promedio de clasificación no aceptables para el usuario, entonces habrá que utilizar alternativas como particionar el conjunto de datos en bins o intervalos de clase. También muchas veces es complicado hallar distribuciones que se comporten como los datos.

28. Si se tiene una solución de AG que utiliza selección elitista 15%, cruza 70% y mutación 15% y no se llega a la solución esperada. ¿Es una buena alternativa cambiar los métodos de cruza y mutación por selección basada en orden? Justificación.

No, no sería una buena alternativa. En todo algoritmo genético es recomendable aplicar los 3 operadores, lo que quizás sería conveniente es cambiar el método de selección o agregar nuevos métodos de selección, ya que me garantiza que la calidad de la población no decaiga de generación en generación, y reasignar los porcentajes.

29. Determine la arquitectura de una red BPN que aproxime la salida de la función sen(x+y/z). Detallar todas las consideraciones de diseño.

Para aproximar la salida de la función f(x,y,z)=sen(x+y/z) con una red BPN se utiliza una arquitectura con 3 neuronas de entrada (xxx, yyy, zzz), una capa y una salida con activación tangencial. Escala los datos de entrada para mejorar la estabilidad del entrenamiento y asegura que z≠0.

30. Explique el algoritmo de aprendizaje de MLP, poner condición de parada (el error global mínimo), función de transferencia. ¿Se puede agregar los errores de entrenamiento, test y validación?

1. *Inicializar los pesos de la red con valores pequeños aleatorios.*
2. *Presentar un patrón de entrada X_p:x_p1,x_p2,x_p3 y especificar la salida deseada que debe generar la red: d_1,d_2,...,d_M*
3. *Calcular la salida actual de la red, para ello presentamos las entradas a la red y vamos calculando la salida que presenta cada capa hasta llegar a la capa de salida; ésta será la salida de la red y_1,y_2,...,yM:*
   a. *Se calculan las entradas netas para cada neurona, procedentes de la capa anterior:*

$$net_{pj} = \sum_{i=1}^{N} w_{ji}\, x_{pi} + \theta_j$$

   siendo opcional θ_jya que actúa como una entrada más, donde j es la neurona actual, i es la neurona anterior, wji es el peso entre la neurona actual y la anterior.
   b. *Se calculan las salidas de las neuronas:*

$$y_{pj} = f_j(net_{pj})$$

   Si la función de activación de la neurona es una función sigmoidal:

$$y_{pj} = \frac{1}{1 + e^{-net_{pj}}}$$

   Si la función de activación de la neurona es una función lineal:

$$y_{pj} = net_{pj}$$

4. *Calcular los términos de error para todas las neuronas.*
   a. *Si la neurona j es de la capa de salida:*

$\delta_{pj} = (d_{pj} - y_{pj}).f_j'(net_{pj}) = (d_{pj} - y_{pj})y_{pj}(1 - y_{pj})$ si f es sigmoidal
$\delta_{pj} = (d_{pj} - y_{pj})$ si f es lineal.
donde δ_j es el error en la neurona j, dj es la salida deseada de la neurona j, yj es la salida obtenida de la neurona j, y $f'(net_j)$ es la derivada de $f(net_j)$

   b. *Si la neurona j no es de salida:*

$\delta_{pj} = f_j'(net_{pj}) \sum_k \delta_{pk}\, w_{kj} = y(1 - y_{pj}) \sum_k \delta_{pk}\, w_{kj}$ si f es sigmoidal
$\delta_{pj} = \sum_k \delta_{pk}\, w_{kj}$ si f es lineal.
donde δ_k es el error en la neurona posterior k, w_{kj} es el peso entre las neuronas k y j

5. *Actualización de los pesos: se comienza por las neuronas de salida y se trabaja hacia atrás hasta llegar a la capa de entrada:*

$$w_{kj}(t+1) = w_{kj}(t) + \alpha\, \delta_{pk}\, y_{pj}$$

donde $w_{kj}(t+1)$ es el peso actualizado entre las neuronas k y j, $w_{kj}(t)$ es el peso anterior entre las neuronas k y j, α es el coeficiente de aprendizaje, δ_{pk}es el error de la neurona posterior k, y_j es la salida de la neurona anterior j

6. *El proceso se repite hasta que el término de error resulta aceptablemente pequeño para cada uno de los patrones aprendidos.*

$$E_{patrón} = \frac{1}{2}\sum_{k=1}^{M} \delta_{pk}^2$$

$$E_{patrón} = \frac{1}{2}\sum_{k=1}^{M} (d_{pk} - y_{pk})^2$$

donde M es la cantidad de neuronas de salida y E_p es el error del patrón. También se puede calcular el Error global

$$E_{global} = \frac{1}{L}\sum_{p=1}^{L} E_p$$

siendo L la cantidad de patrones.

Este error se calcula cuando se terminó una época completa y se presentaron todos los patrones. Si está por debajo del aceptable, se termina. Si no, se hacen los cálculos nuevamente.

El algoritmo finaliza si el error global es menor o igual al mínimo aceptable, también puede finalizar por un número máximo de épocas establecido. Puede finalizar si el error de validación es mayor al error de entrenamiento, en este caso se corta el entrenamiento (early stopping) porque la red empezará a generalizar mal, cayendo en el problema de sobre ajuste, solamente memoriza los ejemplos de entrenamiento y ante nuevos ejemplos no clasifica de manera correcta.

31. Explique las consideraciones que debería tener el diseño de una red MLP para que pueda aprender la siguiente función de variables binarias x, y, z: f(x,y,z) = (x XOR y)XOR z.

Para implementar una MLP que reconozca la función f(x,y,z) = (x XOR y)XOR z, *primero se debe generar un dataset que contenga todas las combinaciones posibles de las variables binarias de (x,y,z) y su correspondiente f(x,y,z). La red tendrá tres neuronas en la capa de entrada (una para x, otra para y y otra para z), dado que la operación XOR no es linealmente separable, la red necesita al menos una capa oculta con n neuronas para la misma, y una neurona en la capa de salida. En la capa de la salida es recomendable usar una función de activación sigmoidal ya que se espera una salida con un rango [0,1].*

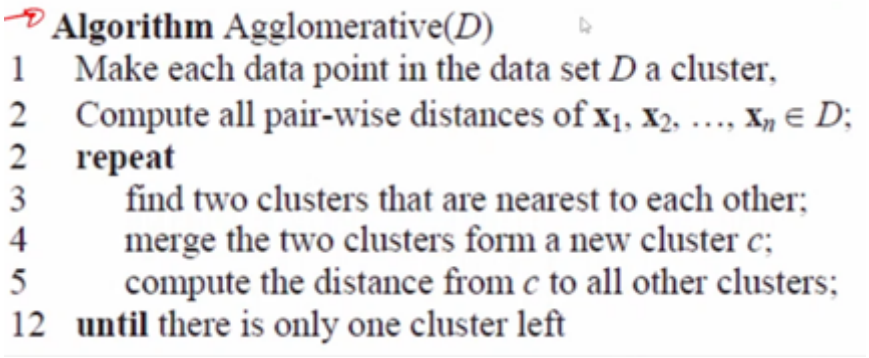
32. ¿Cuáles son las diferencias entre clustering aglomerativo y divisivo? Explique el algoritmo aglomerativo.

El clustering aglomerativo tiene como objetivo principal encontrar todos los grupos o clusters de datos similares existentes en un dataset hasta que no queden datos, va agrupando a los datos en clusters ya sea desde abajo hacia arriba(desde clusters particulares a uno general) o desde arriba hacia abajo(desde cluster general a particulares), de forma tal que al final de su ejecución quede un cluster incluya a todos los datos y a su vez varios clusters anidados de datos similares que se vayan formando durante el proceso. Mientras que en el clustering divisivo el interés principal es dividir al conjunto en k clusters separados y asignar cada uno

de los datos a los mismos. Es decir, en el primero se forman n clusters dependiendo las características intrínsecas de los datos, y en otro una cantidad k fija determinada por el usuario.

Algoritmo aglomerativo:

1. *Recibe el dataset y convierte todos los ejemplos de entrenamiento en un cluster simple.*
2. *Calcula la distancia entre todos los puntos del dataset.*
3. *Selecciona la menor para formar un cluster entre los elementos más cercanos.*
4. *Calcula la distancia desde este nuevo cluster a todos los demás.*
5. *Vuelve a 3 hasta que solo quede un cluster con todos los ejemplos de entrenamiento.*



Algorithm Agglomerative(D)
1 Make each data point in the data set D a cluster,
2 Compute all pair-wise distances of $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n \in D$;
2 **repeat**
3 find two clusters that are nearest to each other;
4 merge the two clusters form a new cluster c;
5 compute the distance from c to all other clusters;
12 **until** there is only one cluster left

33. En Hopfield: ¿Qué significa ek * em>0?

Significa que los patrones aprendidos no son ortogonales, es decir, que no difieren en al menos el 50% de sus componentes unos de otros. Al hacer el producto de las componentes binarias de la misma posición se obtiene +1 cuando son iguales y -1 cuando son distintas, por lo que un valor mayor a 0 implica que más de la mitad de ellas son iguales.

34. Ejemplo diferente al del apunte de ambiente no accesible y ambiente episódico.

Ejemplo: Robot recolector de basura en un terreno irregular

- *No accesible: El robot tiene información limitada sobre el ambiente porque no cuenta con sensores avanzados o datos globales del terreno.*
- *Episódico: Cada decisión del robot (por ejemplo, "recoger basura" o "avanzar") se toma de manera independiente en cada episodio, sin considerar las decisiones anteriores o las consecuencias futuras.*

35. Dificultades del modelo de red de HOPFIELD.

1. *El número de informaciones que puede ser aprendido: si se almacenan demasiadas informaciones, la red recupera resultados incorrectos. Para una recuperación perfecta la cantidad de informaciones debe ser menor o igual N/4lnN donde N = número de neuronas. Esto puede suavizarse si se acepta un pequeño error en la recuperación, aplicando 0.138N que dice que la cantidad de información debe ser menor o igual al 13,8% del número de neuronas. En resumen, se requieren demasiadas neuronas para*

almacenar unas pocas informaciones (100 neuronas almacenarán apenas 13 informaciones).

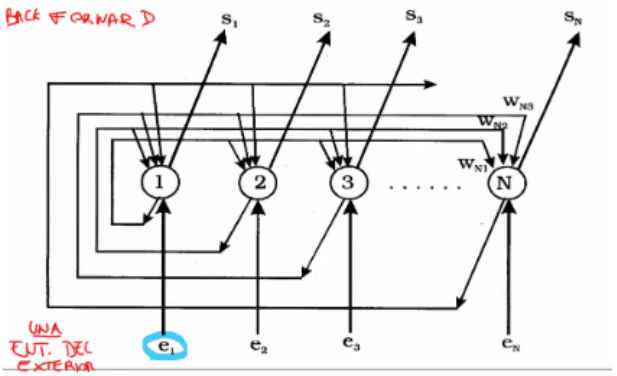
$$\text{Capacidad} = \begin{cases} 0.138 \cdot N & \text{para una recuperación buena} \\ \dfrac{N}{4\ln(N)} & \text{para una recuperación perfecta} \end{cases}$$

2. *Ortogonalidad de las informaciones: A pesar de cumplirse el requisito anterior, no puede garantizarse que asocie correctamente la entrada con la información correcta. Si existen informaciones almacenadas que no son lo suficientemente distintas entre sí, es decir, no son ortogonales, la red podría retornar informaciones diferentes. Se puede minimizar asegurándose las informaciones que debe aprender sean ortogonales, es decir, deben diferenciarse en un 50% los patrones.*

36. Describa la arquitectura del modelo de Hopfield.

La arquitectura del modelo Hopfield es la siguiente:

- *Red monocapa con N entradas y N neuronas de salida.*
- *Posee conexiones laterales, pero no auto recurrentes. Es un modelo back forward.*
- *Produce salidas binarias 0/1 o -1/1 (función escalón), y sus entradas deben estar codificadas con esos valores.*
- *Es una red auto asociativa.*



37. Como funciona el aprendizaje por analogía transformacional.

En el aprendizaje por analogía transformacional se busca tratar de transformar la resolución de un problema viejo al problema nuevo.

38. Explique aprendizaje online y offline.

- Aprendizaje Offline: existe aprendizaje o entrenamiento y una fase de funcionamiento.
- Aprendizaje Online: no existe distingue hace diferenciación de fases, sino que el sistema calcula la salida con los datos existentes cuando necesita brindar una respuesta.

39. Explique el teorema de BAYES y para qué se lo utiliza en los sistemas de clasificación.

El teorema de Bayes es un SBP, se aplica a situaciones no determinísticas. Estima la probabilidad de ocurrencia de un evento dada la ocurrencia de n hechos o sucesos. Se implementa mediante dos modelos:

- *Modelo de síntomas independientes: permite determinar la clase a la que pertenece una instancia encontrando las probabilidades para variables binarias.*
- *Modelo naive bayes: se denomina ingenuo porque considera que todos los eventos son condicionalmente independientes entre sí, algo que por lo general no sucede en la realidad. Se aplica a distribuciones de datos continuas y permite clasificarlos en vj clases de V.*
    - *Distribuciones continuas: se aplica una distribución de probabilidad para calcular las verosimilitudes.*
    - *Histogramas: se aplica cuando no existe distribución de probabilidad que describa los datos. Se organizan los datos en "bins", los cuales luego se utilizan para calcular las verosimilitudes.*

40. ¿Qué tipo de aprendizaje realiza NAIVE BAYES?

Naive Bayes realiza los siguientes tipos de aprendizajes:

- *Aprendizaje offline: primero calcula las probabilidades con los datos de entrenamiento y luego aplica el modelo a las nuevas instancias.*
- *Aprendizaje supervisado: los ejemplos de entrenamiento vienen etiquetados.*

41. Explique el término denominador del TEOREMA DE BAYES.

1. Teorema de Bayes

El teorema de Bayes establece que la probabilidad posterior $P(H \mid S)$, es decir, la probabilidad de una hipótesis H dado un conjunto de hechos S, se calcula como:

$$P(H \mid S) = \frac{P(S \mid H)P(H)}{P(S)}$$

- **Definición**: El denominador $P(S)$ representa la probabilidad conjunta de los hechos o síntomas S, calculada sumando las probabilidades de S bajo todas las hipótesis posibles.
- **Eliminación en Naive Bayes**:
    - Es idéntico para todas las hipótesis H, por lo que no afecta la clasificación relativa entre ellas.
    - Al eliminarlo, se simplifica el cálculo y el modelo se centra en maximizar el numerador $P(S \mid H)P(H)$.

42. Explique por qué el nombre del clasificador Naive Bayes.

*El nombre **"Naive Bayes"** proviene de la simplificación o suposición "ingenua" (**naive**) que realiza este clasificador al aplicar el **Teorema de Bayes**. Se asume que todas las **características (o variables)** son **condicionalmente independientes** entre sí dado el valor de la clase. Esta **suposición de independencia** simplifica enormemente los cálculos, porque: No*

se requiere estimar la probabilidad conjunta P(x1,x2,...,xn | Ck), que puede ser muy compleja. En su lugar, basta con estimar las probabilidades individuales P(xi | Ck).

43. Explique que son las probabilidades a priori y las verosimilitudes.

- ***Probabilidad a priori:*** *Son las probabilidades iniciales de las clases antes de observar cualquier evidencia, basadas en conocimiento previo (P(C).*
- ***Verosimilitudes:*** *Es la probabilidad de un hecho habiendo ocurrido un evento. Si sabemos que ocurrió el evento E, ¿qué probabilidad tiene de presentarse el hecho S? P(S | E).*

44. ¿Por qué se utilizan verosimilitudes?

Se utilizan las verosimilitudes para:

- *Reducen el espacio muestral: Consideramos únicamente los datos que ya han ocurrido (los del data set)*
- *Permite evitar al cálculo de la probabilidad conjunta*

Se utilizan las **verosimilitudes** ($P(E \mid C)$) porque permiten medir qué tan probable es observar un conjunto de datos o evidencia (E) bajo la suposición de que pertenece a una clase específica (C). Esto es fundamental para el **Teorema de Bayes**, ya que combinan la información nueva (evidencia) con las probabilidades a priori para calcular las probabilidades a posteriori ($P(C \mid E)$).

45. ¿Dónde se almacena el conocimiento en el modelo de Bayes?

El conocimiento en el modelo de Bayes se almacena en la base de conocimientos, mediante las probabilidades a priori y las verosimilitudes.

46. ¿Por qué el algoritmo de aprendizaje del modelo MLP se conoce como Backpropagation, si es un modelo feedforward?

El modelo es feedforward porque las neuronas de la red no poseen conexiones con neuronas del mismo nivel o del nivel anterior. Lo que se propaga hacia atrás es el error, dado que para conocer el error de las neuronas de capa oculta, es necesario el error de las neuronas de capa de salida, por eso el nombre de BPN.

47. Explique qué son los errores de entrenamiento, validación y test utilizados en el aprendizaje del modelo MLP.

- *El error de entrenamiento es que el que se busca minimizar mediante la regla delta generalizada y, cuando se alcanza un mínimo establecido, se detiene el aprendizaje.*
- *El error de validación es el que le importa al usuario porque le indica si el modelo tiene buena precisión, se calcula la diferencia entre la etiqueta real y la etiqueta asignada por la red. Este error debe calcularse sobre otros datos distintos a los de entrenamiento, pero*

que también están etiquetados para verificar la precisión. Se suelen dividir los datos en entrenamiento y validación por esta razón. La idea es detener el aprendizaje si este error se dispara porque indica que la red empezó a generalizar demasiado.

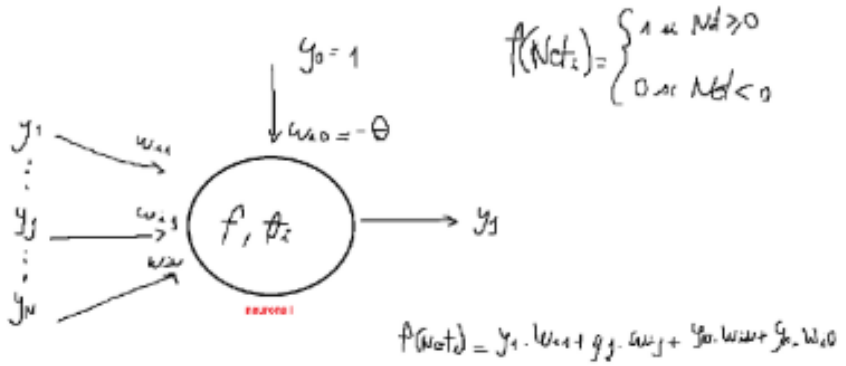
- *El error de test se calcula de la misma manera que el error de validación, pero no detiene el entrenamiento, sino que deja continuar hasta que se alcanza el mínimo establecido. Luego se mide la diferencia entre el error de entrenamiento y el error de test.*

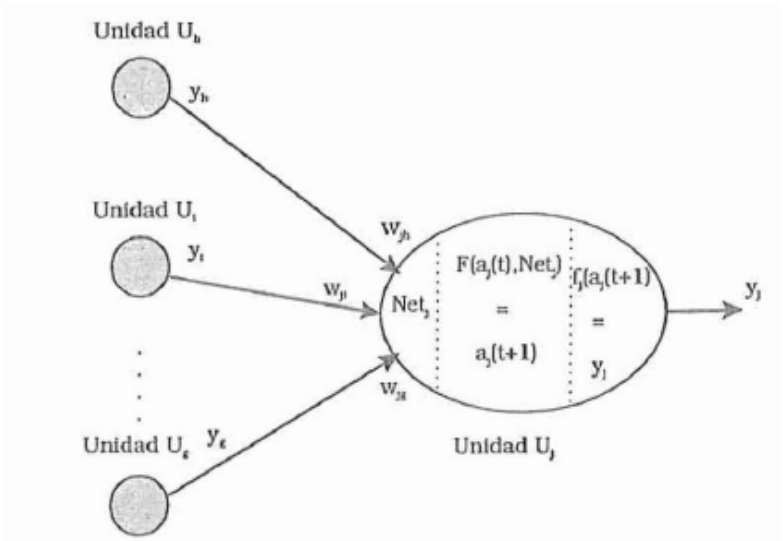
48. ¿El término de momento puede ser negativo? Justifique su respuesta

Cuando β es una constante que consigue la convergencia de la red en menor número de iteraciones: si en t el incremento de un peso era positivo y en t+1 también, entonces el descenso por la superficie de error en t+1 es mayor. Sin embargo, si en t el incremento era positivo y en t+1 es negativo, el paso que se da en t+1 es más pequeño, ya que se ha pasado por un mínimo y los pasos deben ser menores para poder alcanzarlo.

$$w_{ji}(t+1) = w_{ji}(t) + \alpha\, \delta_{pj}\, y_{pi} + \beta(w_{ji}(t) - w_{ji}(t-1))$$

49. Esquematice una neurona artificial e indique los elementos que la constituyen.





50. ¿Qué tipo de neuronas existen?

Existen tres tipos de Neuronas:

- *Neuronas de entrada*
- *Capa oculta*
- *Neurona de salida*

51. ¿Cuál es la función de Transferencia de una neurona? ¿Qué tipos de funciones de transferencia existen?

La función de transferencia se encarga de calcular la salida de la neurona, dado su estado actual o valor de net.

Los tipos de funciones de transferencia que existen son:

- *Escalón: sólo toma dos valores 0 o 1. Existe un umbral que determina el "salto" en la función. No es continua y por lo tanto tampoco derivable. Se usa en perceptrón simple.*
- *Identidad: es una función que devuelve el mismo valor que recibe. Se usa en ADALINE.*
- *Logística o sigmoidal: función cuyo rango va entre [0, 1] pero a diferencia del escalón es continua.*
- *Tangente hiperbólica: su rango va entre [-1 y 1]*

52. Explique redes de propagación hacia adelante y redes de propagación hacia atrás.

- *Feedforward neural network (FNN): es aquella red en la cual la salida de una neurona se propaga siempre hacia el siguiente nivel, nunca hacia neuronas del mismo nivel o hacia neuronas del nivel anterior.*
- *Backforward - red de propagación hacia atrás: es aquella red en la cual existe al menos una neurona cuya salida es entrada de una neurona del mismo nivel o de neuronas del nivel anterior.*

53. Explique aprendizaje en perceptrón simple. Respuesta en Pregunta 17

54. Explique el algoritmo de la Regla Delta Generalizada.

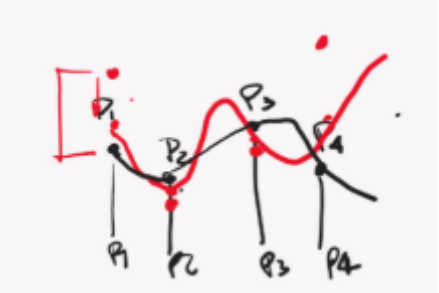
Es la regla Delta extendida a redes con capas intermedias con conexiones hacia adelante. Los pesos se actualizan en forma proporcional al delta, que es la diferencia entre salida deseada y obtenida. La diferencia con la regla delta es en la forma de calcular el delta (o error) porque en las neuronas de capa oculta, no se conoce la salida deseada. Lo que se hace es calcular el error en las neuronas de salida, donde sí se conoce la salida deseada y luego propagar el error hacia atrás, luego se multiplica el error por el peso de la conexión.

- *Para neuronas de salida el error dj = (Sd- So) * f'(netj)*
- *Para neuronas de capa oculta el error dj = (dk * wkj) * f'(netj)*

55. Explique overfitting (sobreajuste)

Cuando se ingresan patrones entrada-salida deseada durante el aprendizaje, se busca que el modelo aprenda y luego pueda determinar la clase de nuevas instancias desconocidas. Puede

suceder que el modelo se adapte muy bien a los ejemplos de entrenamiento (curva negra), pero que presente grandes diferencias para los valores en medio que no conoce (curva roja). Esto indica que la red está sobre ajustada a los ejemplos de entrenamiento y se debe detener el entrenamiento. Se detecta mediante el error de validación.



56. ¿Qué tipo de aprendizaje utiliza el modelo de Hopfield? □ Respuesta en Pregunta 59
57. **¿Qué significa que el modelo de Hopfield es una red auto-asociativa?**

Significa que la red aprende informaciones y las almacena para luego asociarlas a una entrada que más se parezca. Al presentarse una entrada con ruido o distorsión, la red es capaz de encontrar la información almacenada que más se le parezca y devolverla a la salida.

58. **¿Cómo debe representarse la información que recibe el modelo de Hopfield?**

Si la salida es binaria es 0 o 1, la información debe estar codificada en forma de vector con 0 y 1. Por el contrario, si devuelve -1 o 1, las entradas deben estar codificadas de esa manera. La codificación de las entradas depende del formato de las salidas.

59. **Describa la etapa de aprendizaje del modelo de Hopfield.**

Utiliza aprendizaje offline. La fase de entrenamiento o aprendizaje consiste en fijar los valores de los pesos en función de las informaciones que se pretende que la red memorice. Para eso debe confeccionarse la matriz de pesos:

Utilizando la notación anterior el aprendizaje se realiza calculando la matriz de pesos W:

$$W = \sum_{k=1}^{M} \left[E_k^T E_k - I \right]$$

60. **Según sus conexiones, ¿qué tipo de red es el modelo SOM?**

Feedforward: sólo posee conexiones hacia adelante. Las demás líneas son interacciones laterales y auto recurrentes, pero no conexiones.

61. **¿Cómo se modela la influencia de las neuronas entre sí en los SOM?**

Mediante la similitud que exista entre ellas, esa similitud se mide mediante la distancia. Mientras menor sea la distancia, más cercanas están porque son más parecidas. La función de vecindad es la encargada de determinar el valor de influencia de la neurona ganadora sobre las demás, y con eso actualizar los pesos.

62. Describa la etapa de aprendizaje del modelo SOM, especificando claramente las fases de competencia y cooperación.

- *Fase de competencia: se calcula la distancia entre el patrón de entrada y los pesos para determinar qué neurona es la más parecida (menor distancia) a la entrada y activar dicha salida. La distancia se calcula dp1w1 = (w1x1 - x1) - (w1x2 - x2)*
- *Fase de cooperación: una vez seleccionada la neurona ganadora, se deben actualizar los pesos. Si la función de vecindad es nula, sólo se actualiza el peso de la neurona ganadora, si no, el de todas las neuronas, pero teniendo en cuenta que el delta será mayor en aquellas neuronas cercanas a la ganadora.*

63. ¿Qué objetivo tiene la función de vecindad utilizada en los SOM?

La función de vecindad determina el espacio de neuronas alrededor de la ganadora que se van a actualizar y qué tan drástico será el cambio. Las neuronas más cercanas a la ganadora recibirán mayor influencia y por lo tanto el delta de actualización será mayor. La función de vecindad tomará su mayor valor cuando se encuentre sobre la neurona ganadora e irá decreciendo conforme aumenta la distancia.

64. Enumere y explique las diferencias principales entre el modelo de Hopfield y el modelo SOM.

SOM	Hopfield
Es feedforward porque tiene conexiones hacia adelante, pero no hacia atrás ni auto recurrentes	*Es backforward debido a sus conexiones laterales.*
Tiene N entradas y M salidas	*La cantidad de entradas es igual a la cantidad de salidas.*
Conecta las entradas a todas las neuronas de salida	*Una entrada se conecta con una única neurona de salida.*
Los valores de entrada pueden ser reales	*Los valores de entrada deben estar codificados*

65. Explique el concepto de clustering.

Clustering es el proceso de organizar datos en grupos cuyos miembros son similares bajo alguna medida de similaridad. Un cluster es un conjunto de instancias similares entre sí y que son diferentes de otras.

66. Explique cuáles son los tipos de clustering más importantes.

Los tipos de clustering más importantes son:

- *Particional: particiona la data en clusters que va agrupando según su medida de similaridad (k-means, disk-means).*
- *Jerárquico: organiza los datos en clusters anidados que da como resultado una estructura similar a un árbol llamada dendograma, donde las hojas son instancias individuales y la raíz es el conjunto de todas las instancias (aglomerativo, divisivo).*

67. ¿Qué elementos son indispensables para realizar clustering en un conjunto de datos? ¿Esos elementos son complementarios?

Una medida de similaridad que permita determinar la distancia entre instancias de datos y clusters, para luego agruparlos.

68. ¿Qué es un dendograma?

Un dendograma es una estructura anidada de clusters con forma de árbol que se utiliza para representar clustering jerárquico. Las hojas representan datos individuales del dataset, mientras que la raíz representa un cluster con todos los ejemplos de entrenamiento.

69. ¿Cuál es el objetivo del clustering? Explique el concepto de agrupamiento intrínseco.

El objetivo del clustering es encontrar similitudes entre los datos de entrada para agruparlos mediante un algoritmo de clustering y medidas de distancia. El clustering es un modelo de agrupamiento, que dentro de un mar de datos busca patrones intrínsecos en cada uno de los datos que le permita agruparlos según sus similitudes.

70. Explique el algoritmo k-means presentado en el material de referencia.

Algoritmo k-means

1. *seleccionar k semillas iniciales que son tomadas como centroides de un cluster.*
2. *para cada punto del data set se calculan las distancias hacia los centroides y se los agrupa en el cluster que tenga el centroide más cercano.*
3. *se vuelve a calcular los centroides.*
4. *si no hubo cambios en centroides, variaciones en los errores mínimos o reasignaciones, se para el algoritmo.*

Algorithm *k*-means(*k*, *D*)

```
1  choose k data points as the initial centroids (cluster centers)
2  repeat
3     for each data point x ∈ D do
4        compute the distance from x to each centroid;
5        assign x to the closest centroid        // a centroid represents a cluster
6     endfor
7     re-compute the centroid using the current cluster memberships
8  until the stopping criterion is met
```

71. Enumere y explique las ventajas y desventajas del algoritmo k-means.

Ventajas	Desventajas
Simplicidad y eficiencia	*Sólo se puede aplicar a datasets donde exista la noción de media.*
Fácil de entender e implementar	*El usuario debe especificar la cantidad de clusters.*
Complejidad temporal lineal, no exponencial	*El algoritmo es sensible a semillas iniciales: semillas iniciales distintas pueden retornar clusters distintos, obteniendo mínimos locales en vez de absolutos.*
Se considera algoritmo lineal	*El algoritmo es sensible a outliers: identificarlos y eliminarlos antes de aplicar el algoritmo.*

<u>Nota:</u> Solución a la sensibilidad de semillas iniciales Se calcula la media del conjunto, y se elige el punto más alejado como centroide. Luego, parado sobre el nuevo centroide, elegir el dato más alejado como segundo centroide. Para el tercer centroide, calcular el dato más alejado de ambos centroides a la vez. Repetir para los demás centroides.

72. **Explique el algoritmo knn presentado en el material de referencia.**

Algoritmo Knn:

1. *calcular la distancia desde la nueva instancia a todos los demás puntos del conjunto*
2. *ordenar las distancias de menor a mayor*
3. *elegir los k elementos más cercanos llamados "vecinos"*
4. *la clase que más ocurrencias tenga entre los vecinos es la que se asigna a la nueva instancia.*

Training algorithm:

- For each training example $\langle x, f(x) \rangle$, add the example to the list *training_examples*

Classification algorithm:

- Given a query instance x_q to be classified,
  - Let $x_1 \ldots x_k$ denote the k instances from *training_examples* that are nearest to x_q
  - Return

$$\hat{f}(x_q) \leftarrow \underset{v \in V}{\operatorname{argmax}} \sum_{i=1}^{k} \delta(v, f(x_i))$$

where $\delta(a, b) = 1$ if $a = b$ and where $\delta(a, b) = 0$ otherwise.

73. Explique cómo calcular el valor de k óptimo para la ejecución del algoritmo knn.

Para calcular el valor del k óptimo en la ejecución del algoritmo knn se debe aplicar un algoritmo que permita medir la precisión de las clasificaciones, como k-fold cross validation.

74. Explique los métodos de selección proporcionales. Ejemplifique.

Los métodos de selección proporcionales son los que tienen en cuenta la aptitud de los individuos respecto a la población. Su problema es la convergencia prematura ya que puede pasar que los mejores individuos dominen a la población rápidamente.
Entre los métodos se encuentran:

- *Selección elitista: preserva los mejores individuos para la siguiente generación sin evaluación.*
- *Selección por ruleta: es un método probabilístico que asigna ranuras a los individuos proporcional a su aptitud.*
- *selección con control de copias → se utiliza el promedio de la aptitud de la población para calcular c = fi/f ; c = cant de copias, fi = aptitud individuo y f = aptitud promedio población*

75. Explique los métodos de selección basados en orden. Ejemplifique.

*Los métodos de selección basados en orden tienen en cuenta una lista ordenada según la aptitud de los individuos. Entre ellos existe la selección por ranking, en la que cada individuo recibe una cantidad de copias según su posición en una lista ordenada por aptitud. Se utiliza la fórmula c = r min + 2 *(n - i)* (1 – r min) / n -1, donde r min es el número mínimo de copias*

76. Explique los métodos de cruce. Ejemplifique.

El cruce es otro operador que se encarga de recombinar individuos de la población generando nuevos no existentes. Existen varios métodos:

- *cruce simple: establece un punto de corte y combina los segmentos para formar los hijos.*
- *cruce multipunto: se establecen varios puntos de corte y se segmentan.*
- *cruce binomial: por cada característica se selecciona con probabilidad p un elemento del padre y probabilidad 1 -p un elemento de la madre. Se define la probabilidad para cada atributo y se asigna una ruleta entre cada atributo. SI p = 0.5 entonces el cruce es uniforme.*

77. Explique los métodos de mutación adaptativa por convergencia. Ejemplifique.

La mutación es utilizada para mantener la diversidad de la población, si un individuo es seleccionado para mutar entonces muta si o sí. Existe la mutación constante y adaptativa.
La mutación adaptativa por convergencia consiste en variar en función a la diversidad de la población, cuando más homogénea esta, mayor es la probabilidad de mutación. Ejemplo: cantidades iguales / población.

78. Explique los métodos de mutación adaptativa por temperatura. Ejemplifique.

La mutación adaptativa por temperatura no usa la diversidad, sino que se basa en el tiempo, es decir en la cantidad de generaciones. Los métodos de este tipo de mutación son:

- *Temperatura ascendente: arranca con un valor mínimo y aumenta a medida que van pasando las generaciones, suele existir un valor máximo y ahí decidir si se trabaja con ese hasta el final o se reinicia el valor y se comienza de nuevo con la mínima. Ejemplo: se utiliza ya que se dice que en las primeras iteraciones la población es heterogénea.*
- *Temperatura descendente: arranca con un valor máximo y disminuye a medida que van pasando las generaciones. Suele existir un valor mínimo y se decide si se va a trabajar con el o se va a reiniciar el valor y comenzar nuevamente con la máxima. Ejemplo: se la utiliza porque en las primeras iteraciones se puede explorar más el espacio de búsqueda.*

Preguntas Parciales de Opciones Múltiples

1. En clustering jerárquico, la distancia entre dos clusters:

Se calcula utilizando la máxima distancia de sus centroides si se emplea el método complete-link.	V	F
Se calcula utilizando la mínima distancia de sus centroides si se emplea el método single-link.	V	F
Se calcula utilizando el promedio de la distancia de sus centroides si se emplea el método average-link.	V	F

2. Para utilizar el algoritmo k-nn ponderado:

No es necesario que las clases sean linealmente separables	V	F
Es necesario establecer previamente el valor del k-óptimo	V	F
Puede utilizarse todo el conjunto de datos para estimar la clase de una nueva instancia	V	F

3. El algoritmo Disk k-means:

Retorna los mismos clusters que la versión k-means si las semillas utilizadas en ambos casos son las mismas	V	F
Requiere establecer la cantidad de clusters al inicio de la ejecución	V	F
Permite analizar distintas configuraciones de clusters para seleccionar la adecuada	V	F

4. En SVM:

Los vectores de soporte son aquellos cuyo alfa es distinto de 0.	V	F
Se recalcula el método cuando ingresa una nueva instancia de entrenamiento.	V	F
Entre H+ y H- no existen instancias de entrenamiento.	V	F
Ninguna de las anteriores	V	F

5. En el modelo Hoplfield, el concepto de ortogonalidad está asociada a:

La cantidad de información que puede almacenar la red.	V	F
Al grado de diferencia que hay entre los patrones de entrenamiento	V	F
A la complejidad de los cálculos en el proceso de entrenamiento.	V	F

6. El algoritmo K-means:

Es un método de clasificación local	V	F
Es un método de clasificación lazy	V	F
Es un algoritmo de aprendizaje supervisado	V	F
Ninguna de las anteriores	V	F

7. El algoritmo k-nn:

Es lazy	V	F
Es un método local	V	F
Requiere una cantidad parecida de instancias en las clases	V	F
Ninguna de las anteriores	V	F

8. En k-nn se tienen p instancias de la clase A y q instancias de la clase B. Se presenta una nueva instancia para clasificar siendo k=p+q (todo el conjunto):

Se clasifica como A si p>q	V	F
Se clasifica como B si p<q	V	F
No se puede determinar de antemano sin haber calculado las distancias con la nueva instancia	V	F

9. En clustering jerárquico:

En single link la distancia entre dos clusters es la distancia mínima entre sus centroides.	V	F
En complete link la distancia entre dos clusters es la distancia máxima entre sus centroides.	V	F
En average link la distancia entre dos clusters es la distancia promedio entre sus centroides	V	F

10. En una SVM, los vectores que no son de soporte tienen asociados multiplicadores de Lagrange cuyos valores son:

Positivos	V	F
Ceros	V	F
Negativos	V	F

11. La cantidad de patrones (M) que puede memorizar una red de Hopfield de N neuronas para una recuperación buena es:

M = M / 4 x ln(N)	V	F
N = M / 4 x ln(M)	V	F
N = N / 4 x ln(M)	V	F
M = N / 4 x ln(N)	V	F

12. En la fase de competencia del entrenamiento de un SOM:

Las mejores entradas definen la influencia en las neuronas de salida	V	F
Se establece la magnitud de actualización de los pesos mediante la función de vecindad.	V	F
Se establece la neurona de salida ganadora.	V	F
Las entradas compiten por alcanzar a la mejor neurona de salida.	V	F

13. La cantidad de entradas de un SOM está definida:

La cantidad de conexiones	V	F
Las dimensiones del problema	V	F

La cantidad de pesos de las conexiones.	V	F
El diseñador de la red	V	F

14. Las SVM (caso lineal) realizan separaciones lineales:

Solamente en problemas de clasificación de dos dimensiones.	V	F
Solamente en problemas de clasificación de dos clases	V	F
En problemas de clasificación de varias clases (mayor a dos clases).	V	F
En problemas de clasificación de varias dimensiones (mayor a dos dimensiones)	V	F

Preguntas Parcial Anterior

1. El ***término de momento*** se utiliza para acelerar la convergencia de la red durante el entrenamiento, reduciendo el número de iteraciones necesarias para alcanzar el mínimo del error. Esto se logra añadiendo un término adicional, denominado *"momento"* (β(w(T)-W(T-1)))), a la ecuación de actualización de pesos. β es una constante que determina el efecto en t+1 del cambio de los pesos en t, teniendo en cuenta el peso actual y el anterior para definir el incremento.

2. La ***mutación adaptativa por temperatura*** no usa la diversidad, sino que se basa en el tiempo, es decir en la cantidad de generaciones. Los métodos de este tipo de mutación son:
   - ***Temperatura ascendente:*** Arranca con un valor mínimo y aumenta a medida que van pasando las generaciones, suele existir un valor máximo y ahí decidir si se trabaja con ese hasta el final o se reinicia el valor y se comienza de nuevo con la mínima. Ventaja: Evita la mutación prematura al individuo con mayor aptitud.
   - ***Temperatura descendente:*** Arranca con un valor máximo y disminuye a medida que van pasando las generaciones. Suele existir un valor mínimo y se decide si se va a trabajar con él o se va a reiniciar el valor y comenzar nuevamente con la máxima. Ventaja: Mejora la exploración inicial, esto permite ampliar el espacio de búsqueda de soluciones del problema.

3. **Feedforward neural network (FNN):** Es aquella red en la cual la salida de una neurona se propaga siempre hacia el siguiente nivel, nunca hacia neuronas del mismo nivel o hacia neuronas del nivel anterior. (Ejemplos: Perceptrón, Adaline, MLP,)
   Backforward - Red de propagación hacia atrás: Es aquella red en la cual existe al menos una neurona cuya salida es entrada de una neurona del mismo nivel o de neuronas del nivel anterior. (Ejemplos: Hopfield)

4. **A. El número de informaciones que puede ser aprendido:** Si se almacenan demasiadas informaciones, la red recupera resultados incorrectos. Para una recuperación perfecta la cantidad de informaciones debe ser menor o igual N/4lnN donde N = número de neuronas. Esto puede suavizarse si se acepta un pequeño error en la recuperación, aplicando 0.138N que dice que la cantidad de información debe ser menor o igual al 13,8% del número de neuronas. En resumen, se requieren demasiadas neuronas para almacenar unas pocas informaciones (100 neuronas almacenarán apenas 13 informaciones).

   B. Ortogonalidad de las informaciones: A pesar de cumplirse el requisito anterior, no puede garantizarse que asocie correctamente la entrada con la información correcta. Si existen informaciones almacenadas que no son lo suficientemente distintas entre sí, es decir, no son ortogonales, la red podría retornar informaciones diferentes. Se puede minimizar asegurándose las informaciones que debe aprender sean ortogonales, es decir, deben diferenciarse en un 50% los patrones.