Algoritmos Genéticos

Norm = (Aptitud / SumAptitud) * 100

Selección por ruleta

Individuo	Aptitud	Normalización	Copias esperadas	Ranuras		Asignación 1
I01	38	12.26	12	0	11	2
I02	14	4.52	4	12	15	15

Mutación Adaptativa por Temperatura

$$p_m[t+1] = p_m[t] \pm |\lambda|$$

Selección con Control sobre el Número Esperado (o con control de copias)

$c_i = f_i/\bar{j}$ Ci = Aptitud / PromAptitud

$$P_m^{min} \geq P_m(t) \geq P_m^{max}$$

Selección por ranking

$$R_{min} + 2\frac{(n-i)(1-R_{min})}{n-1}$$

Individuo	Aptitud	Nro en Orden	Cantidad de Copias
I06	65	1	2
I07	43	2	2

Naive Bayes - Distrib de Prob

$$p(e_i|s_1,\ldots,s_k) = \frac{p(e_i)p(s_1,\ldots,s_k|e_i)}{\sum_{e_i} p(e_i)p(s_1,\ldots,s_k|e_i)} \propto p(e_i)\prod_{j=1}^{n} p(s_j|e_i).$$

PROBABILIDAD A POSTERIORI = PROBABILIDAD A PRIORI * VEROSIMILITUD

Verosimilitud

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{(x-\mu)^2}{2\sigma^2}}$$

Desviación Estándar

$$\sigma = \sqrt{\frac{\sum_1^N (x_i - \bar{X})^2}{N}}$$

- X → Variable
- x_i → Observación número i de la variable X.
- N → Número de observaciones.
- $\bar{X}$ → Es la media de la variable X.

Naive Bayes - Histogramas

$$P(C1 \mid d1, d2) \propto p(C1) * \prod_{i=1}^{2} p(di/C1) \propto p(C1) * p(d1/C1) * p(d2/C1)$$

$$P(C1 \mid d1, d2) \propto 0,4 * \left(\frac{1}{1.1*\sqrt{2\pi}} e^{-\frac{(3-2.1)^2}{2*1.1^2}} * \frac{1}{2*\sqrt{2\pi}} e^{-\frac{(-1-3.1)^2}{2*2^2}}\right)$$

Se calculan las probabilidades a priori de cada clase, mediante la formula

$$p(Ti) = \frac{\#Ti}{\#Total}$$

y luego las verosimilitudes según el bins definidos

$$p(vi|Ti) = \frac{\#vi}{\#Ti}$$

Luego se calcula la probabilidad de pertenencia a cada clase de la instancia presentada

$$p(Ti|v1,\ldots,vn) = p(Ti) * \prod_{j=1}^{n} p(vj|Ti)$$

Se considera como elegida a la que tenga mayor probabilidad, pero se puede armar un ranking presentando los resultados.

$$P(T1 \mid v1, v2) \propto p(T1) * \prod_{i=1}^{2} p(vi/T1) \propto p(T1) * p(v1/T1) * p(v2/T1)$$

$$P(T1 \mid v1, v2) \propto 0,3 * \left(\frac{5500}{37500} * \frac{5000}{37500}\right) = 0.006$$

Perceptrón - Método Analítico ($-w_0 = \Theta$)

$$1 * (-\theta) + x_1 * w_1 + x_2 * w_2 = 0$$

$$x_2 = -\frac{w_1}{w_2} * x_1 + \frac{\theta}{w_2}$$

hay error, cambio el signo de θ y determino nuevamente los pesos:

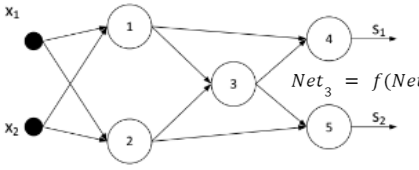
Método Iterativo

$$Error = S_{d1} - f(Net)$$

$$Net = x0 * w0 + x1 * w1 + x2 * w2$$

$$w_i(t+1) = w_i(t) + \alpha[d(t) - y(t)]x_i(t)$$

MLP - Salidas



$$Net_1 = x_1 * w_{1x1} + x_2 * w_{1x2}$$

$$Net_2 = x_1 * w_{2x1} + x_2 * w_{2x2}$$

$$Net_3 = f(Net_1) * w_{31} + f(Net_2) * w_{32}$$

Neuronas 1, 2, 3: lineales

$$f(Net_1) = Net_1 \qquad f'(Net_1) = 1$$

Neuronas 4, 5: sigmoidales

$$f(Net_4) = \frac{1}{1+e^{-Net_4}} = S_1 \qquad f'(Net_4) = f(Net_4)(1 - f(Net_4))$$

Errores

$$E_{s1} \rightarrow \frac{(S_{d1} - S_{01})^2}{2}$$

$$E_{s2} \rightarrow \frac{(S_{d2} - S_{02})^2}{2}$$

$$Error\ de\ patrón\ 1 = E_{s1} + E_{s2}$$

Error Neuronas de Salida

$$\delta_4 = (S_{d1} - f(Net_4)) * f'(Net_4)$$

$$\delta_5 = (S_{d2} - f(Net_5)) * f'(Net_5)$$

Error Neuronas Ocultas

$$\delta_3 = (\delta_4 * w43 + \delta_5 * w53) * f'(Net_3)$$

$$\delta_1 = (\delta_4 * w41 + \delta_3 * w31) * f'(Net_1)$$

$$\delta_2 = (\delta_5 * w52 + \delta_3 * w32) * f'(Net_2)$$

Actualización de los pesos:

$$w_{1x1}(t+1) = w_{1x1}(t) + \alpha * \delta_1 * x_1 \qquad w_{31}(t+1) = w_{31}(t) + \alpha * \delta_3 * f(Net_1)$$

$$w_{1x2}(t+1) = w_{1x2}(t) + \alpha * \delta_1 * x_2 \qquad w_{32}(t+1) = w_{32}(t) + \alpha * \delta_3 * f(Net_2)$$

Término Momento = Beta

$$w_{ji}(t+1) = w_{ji}(t) + \alpha\ \delta_{pj}\ y_{pi} + \beta(w_{ji}(t) - w_{ji}(t-1)) = \Delta w_{ji}(t+1) = \alpha\ \delta_{pj}\ y_{pi} + \beta\ \Delta w_{ji}(t)$$

Hopfield - Aprendizaje (Matriz de Pesos)

$$W = \sum_{k=1}^{M} [E_k^T E_k - I]$$

Condición de ortogonalidad

$$\sum_{i=1}^{N} ei(k).ei(m) \leq 0 \quad para\ todo\ k\ distinto\ de\ m$$

SOM (Distancia)

$$Sj = 1 \quad MIN\ dj = \sum_{i=1}^{N} (ei^{(k)} - wji)^2$$

$$W_{2.1}(t+1) = w_{2.1}(t) + h_{ij} * \alpha(t) * (e^k_1 - w_{2.1})$$

$$\alpha(t) = 1/t$$

Función vecindad h

KNN

$$d(x_i, x_j) \equiv \sqrt{\sum_{r=1}^{n} (a_r(x_i) - a_r(x_j))^2}$$

$$f(x_q) \leftarrow \underset{v_j \in V}{argmax} \sum_{i=1}^{k} \delta(v, f(x_i))$$

Donde $\delta(a,b) = 1$ si $a = b$ y donde $\delta(a,b) = 0$ en otro caso.

Ponderado $f(x_q) \leftarrow \underset{v_j \in V}{argmax} \sum_{i=1}^{k} \omega_i \delta(v, f(x_i))$ $\omega_i \equiv \frac{1}{d(x_q,x_i)^2}$ $\frac{1}{distancia^2}$

e1	e2	e3	e4	e5	e6	# k
e5	e1	e2	e5	e4	e5	5
e4	e3	e3	e1	e3	e3	2
e3	e4	e5	e6	e1	e4	4

K-means

I	x	y	z
1	2.1	1.4	3
2	2.5	2	4
3	3.2	0.4	5
4	-1.5	-2	3
5	-3.2	-0.3	1.2
6	1	1	1

ITERACION 1

I	Distancia S/C1	Distancia S/C2
1	1.232882801	2.491987159
2	0	2.01246118
3	2.01246118	0
4	5.744562647	5.643580424
5	6.754257916	7.475961477
6	3.5	4.604345773
	4	2

I	x	y	z
1	2.1	1.4	3
2	2.5	2	4
5	-3.2	-0.3	1.2
6	1	1	1
Centroide 1	0.6	1.025	2.3
3	3.2	0.4	5
4	-1.5	-2	3
Centroide 2	0.85	-0.8	4

$$mj = \frac{1}{|Cj|} \sum_{xj \in Cj} xj$$

Clustering

Aglomerativo (Bottom Up)

Divisivo (Top Down)

Single Link: Distancia entre los dos puntos de datos más cercanos en ambos clusters.
Complete Link: Distancia entre los dos puntos de datos más lejanos en ambos clusters.
Average Link: Promedio de distancias entre los elementos de cada cluster.